RELATÓRIO TÉCNICO: Predição de Pico de Risco Cardíaco

1. Introdução

Este relatório documenta as decisões técnicas, a avaliação de desempenho e as reflexões acerca do modelo de Machine Learning desenvolvido para prever picos de risco cardíaco em pacientes. O sistema foi construído sobre uma base de dados sintética com 5.000 registros de sinais vitais e métricas operacionais hospitalares, servindo como motor de inferência para a arquitetura multi-agente subsequente.

2. Decisões do Modelo e Justificativa do Algoritmo

O algoritmo selecionado para a tarefa de classificação binária (Risco vs. Sem Risco) foi o **RandomForestClassifier**. A escolha baseia-se em quatro pilares fundamentais adequados ao contexto de saúde digital:

- **Captura de Relações Não-Lineares:** O risco clínico não escala de forma linear. O Random Forest consegue mapear limiares compostos (ex: saturação baixa simultânea a uma alta carga do sistema hospitalar) de forma nativa.
- **Adequação a Dados Tabulares:** Para bases de dados estruturadas com múltiplas features contínuas e discretas (como sinais vitais), métodos baseados em árvores (*ensembles*) superam algoritmos mais simples e exigem menos transformações matemáticas prévias.
- **Prevenção de Overfitting:** Por ser um método de *Ensemble* (conjunto de múltiplas árvores de decisão que votam na classe final), o algoritmo reduz a variância e aumenta a capacidade de generalização do modelo para novos pacientes.
- **Robustez à Escala das Variáveis:** O modelo lida perfeitamente com variáveis em escalas heterogêneas sem a necessidade imperativa de normalização prévia.

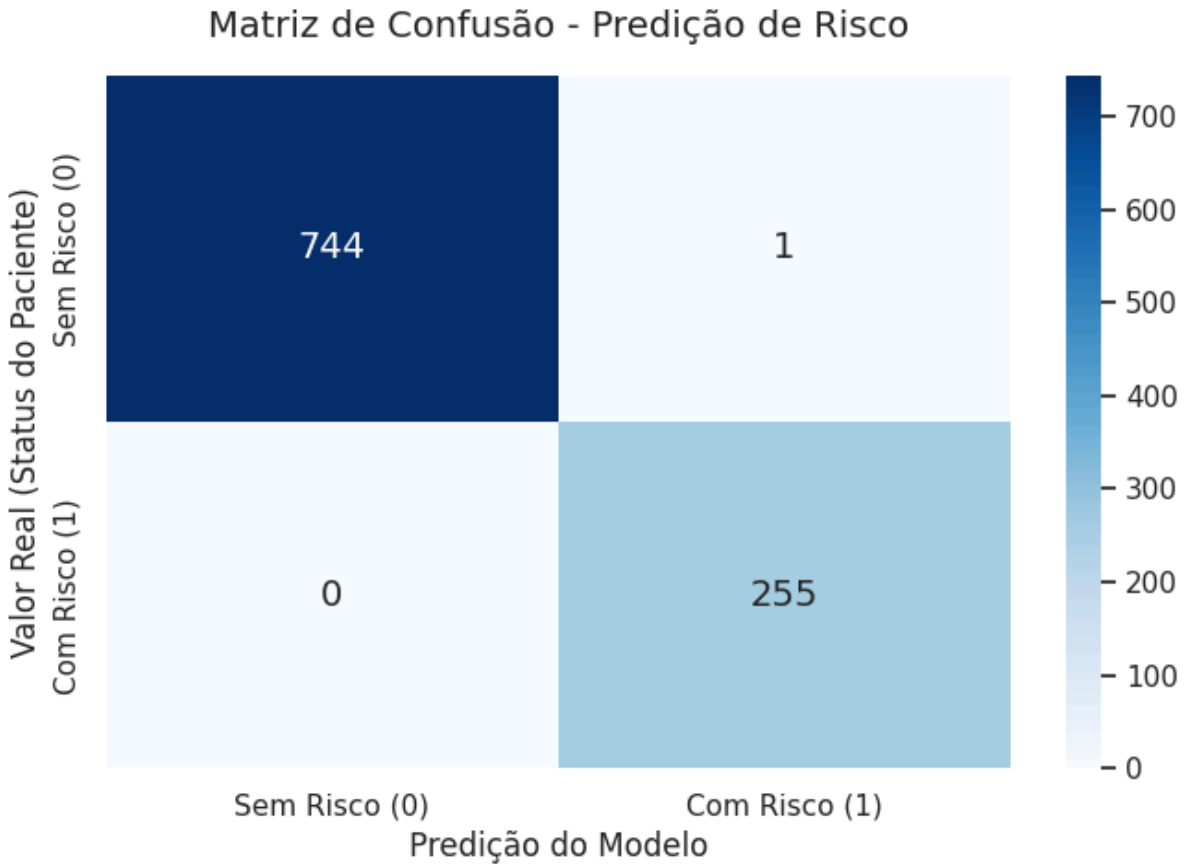
3. Avaliação e Interpretação das Métricas

O modelo foi avaliado utilizando uma separação de 80% dos dados para treinamento e 20% para teste. A métrica primária de desempenho obtida foi a **Acurácia de 1.00 (100%)**.
Uma acurácia perfeita em cenários clínicos reais é praticamente inatingível. Neste projeto, o desempenho impecável reflete a natureza determinística da base de dados sintética. Como a variável alvo (`pico_risco`) foi matematicamente derivada dos dados de entrada através de limiares exatos fixados em código, o Random Forest foi capaz de decifrar e mapear essa "equação" subjacente com total precisão.

4. Análise da Matriz de Confusão

A Matriz de Confusão gerada nos dados de teste evidenciou o seguinte cenário:

- **Verdadeiros Negativos (744):** Pacientes corretamente classificados como "Sem Risco", otimizando recursos hospitalares.
-
- **Verdadeiros Positivos (255):** Pacientes corretamente identificados em "Pico de Risco", permitindo o acionamento de protocolos no tempo ideal.
-
- **Falsos Positivos (1):** Um único paciente sem risco foi classificado com risco. No domínio da saúde, este erro é altamente tolerável, resultando apenas em observação cautelar.
-
- **Falsos Negativos (0):** Nenhum paciente em risco foi liberado incorretamente. Este é o indicador mais crítico de sucesso do projeto na triagem emergencial.

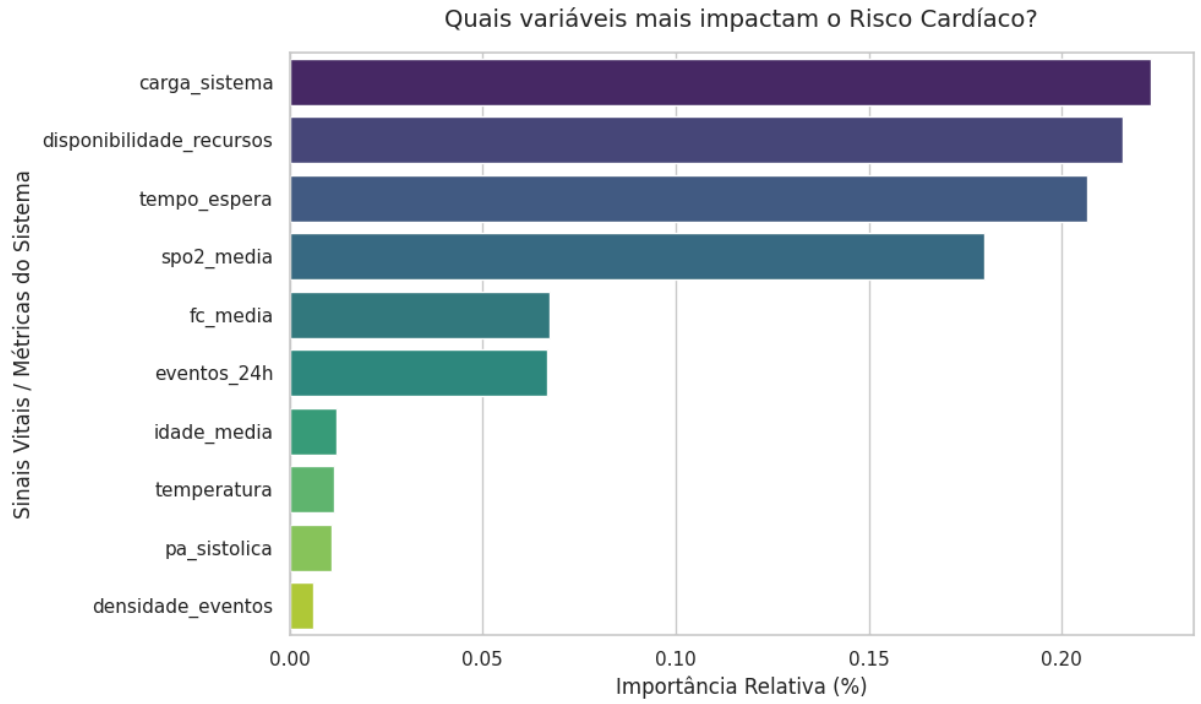


5. Análise de Importância das Variáveis (Feature Importance)

A extração da importância das variáveis do modelo comprovou que o algoritmo capturou com exatidão a lógica de geração dos dados. As três variáveis de maior impacto na decisão de risco foram métricas estritamente operacionais:

1. carga_sistema (maior peso isolado)
2. disponibilidade_recursos
3. tempo_espera

O sinal vital de maior peso foi a spo2_media, ocupando o quarto lugar geral. Em contrapartida, variáveis que não integravam a regra matemática original geradora da base — como idade_media, temperatura, pa_sistolica e densidade_eventos — tiveram peso estatístico próximo a zero, comprovando que o modelo isolou corretamente os fatores determinantes sem sofrer ruído.



6. Validação Prática: Simulação de Novo Paciente

Para validar a capacidade de generalização e a lógica do modelo, um paciente simulado foi submetido ao sistema, apresentando o seguinte quadro: saturação (spo2_media) de 89%, alta carga_sistema (92), tempo_espera elevado (75 min) e baixa disponibilidade_recursos (25%).

O modelo retornou uma **probabilidade de risco de 0.98 (98%)**. Este resultado demonstra extrema coerência com a análise de importância das variáveis (Seção 5): o paciente simulado ultrapassou os limiares críticos de todas as quatro variáveis que o modelo

aprendeu a priorizar. A predição quase absoluta de risco confirma que o algoritmo hierarquizou e aplicou corretamente a gravidade de cada métrica para um caso de emergência.

7. Reflexão, Limitações e Melhorias Futuras

Embora os resultados técnicos sejam excepcionais, a principal limitação deste projeto é o uso de dados 100% sintéticos e gerados por regras estáticas. A biologia humana possui ruídos, dados ausentes e correlações não contempladas na simulação atual.